# Etude empirique

Le générateur de vidéos permet de produire des variantes de vidéos, c'est-à-dire des séquences vidéos qui ont été concaténées, à partir d'une spécification (au sein d'un fichier .videogen). Or, les playlists créées peuvent devenir très volumineuses si les séquences vidéos la constituant sont volumineuses ou que le nombre de ces séquences est élevé.

Il est alors intéressant, voire crucial, de pouvoir déterminer si la variante à générer sera volumineuse ou non. On pourra ainsi empêcher la production d'une variante trop volumineuse grâce à un seuil de taille maximale.

Une façon simple d'estimer la taille de la variante est de la déduire de la somme de la taille de toutes les vidéos constituant la playlist. Par conséquent, l'objectif de cette étude est de déterminer empiriquement la relation entre la somme de la taille des vidéos et la taille réelle de la playlist. L'étude porte également sur l'impact du format GIF et des différents filtres sur la taille d'une variante.

## Matériel

L'étude a été réalisée avec les fichiers suivants :

- Script R: jbsrs/videogentransformations/empiricalStudy/script R empirique.R
- Spécifications
  - jbsrs/videogentransformations/empiricalStudy/specs/sample\_\*.videogen
- Fichiers csv générés à partir de notre application
  - jbsrs/videogentransformations/empiricalStudy/analyses/analysis\_\*.csv
- Vidéos utilisées : jbsrs/videogentransformations/empiricalStudy/videos/\*.mp4

N.B: Les fichiers de spécifications (.videogen) sont à personnaliser avec le chemin vers le projet VideoGen2!

#### Méthode

Nous utilisons un échantillon de vidéos relativement peu volumineuses ainsi que plusieurs spécifications pour générer des variantes et comparer leur taille selon les conditions (taille réelle, format GIF, filtres).

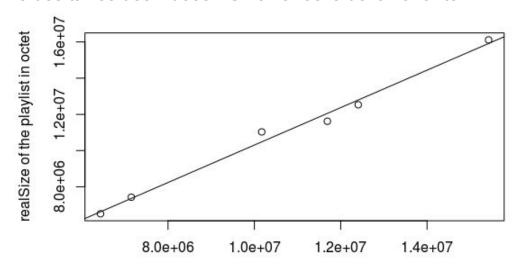
Pour définir une relation entre la somme des tailles des vidéos et la taille réelle d'une variante, nous nous basons sur la régression linéaire et plus particulièrement sur le test statistique de corrélation de Pearson qui permet de déterminer si deux variables sont corrélées par un coefficient. Nous fixons un seuil d'erreur de 5% pour le test statistique. Ainsi, si la p-valeur du test est inférieur à ce seuil, nous pouvons rejeter l'hypothèse supposant que les deux variables ne sont pas corrélées avec un taux d'erreur de 5%. On peut alors estimer que les variables sont reliées par la relation suivante :

variable A = variable B \* coefficient de corrélation de Pearson

Pour effectuer l'étude de régression linéaire et les tests statistiques, le script R a été exécuté depuis RStudio. Les résultats sont présentés ci-après.

## Résultat

Somme des tailles des vidéos VS Taille réelle de la variante



sum of the size of the videos in a playlist in octet

La p-valeur du test statistique est de 3,744e-05 donc inférieur à 5%, ce qui nous permet de rejeter l'hypothèse H0 qui consiste à dire qu'il n'y a pas de corrélation entre la somme des tailles de vidéos et la taille réelle de la playlist. Le coefficient de corrélation de Pearson obtenu nous permet donc d'estimer la taille réelle de la playlist avec 5% d'erreur. Ainsi, on utilisera la relation suivante :

Taille réelle de la playlist = Somme de la taille des vidéos / coefficient de corrélation avec coefficient de corrélation ~ 0,994996.

Nous réalisons le même raisonnement pour les autres conditions de l'étude.

#### Autres conditions

La relation entre la taille de la variante sans filtre et celle avec filtre peut s'écrire comme-ci : Taille réelle de la variante avec condition = Taille réelle de la variante format video \* coefficient de corrélation

Condition	coefficient de corrélation	P-valeur	Action sur la concaténation (taille)
Filtre negate	~ 0.9999846	3.538e-10	Réduction
Filtre black&white	~ 0.9958823	2.54e-05	Réduction
Filtre flip horizontal	~ 0.9999429	4.889e-09	Réduction
Filtre flip vertical	~ 0.9999415	5.126e-09	Réduction
Format GIF	~ 0.9755055	0.0008926	Réduction

### Conclusion

Nous avons observé qu'après concaténation par Ffmpeg la taille d'une variante était supérieure à la somme des tailles des vidéos la constituant. De plus, une variante au format GIF possède une taille inférieure à celle au format video (mp4). Enfin, l'utilisation des filtres

(negate, black&white, flip) a tendance à réduire la taille de la variante. Il n'y a donc pas de précautions particulières à prendre vis-à-vis de l'utilisation ces derniers lors de la concaténation.

Pour éviter la génération de variantes trop volumineuses, nous pouvons utiliser nos résultats. En effet, avant chaque appel à la fonction FFMPEGHelper.concatVideos() permettant de générer la variante, nous pouvons estimer la taille réelle de la variante à partir de la somme des tailles des vidéos de la variante en appliquant la formule associée (cf Résultats). Cette taille réelle estimée sera ensuite ajustée selon la présence de conditions particulières (filtre, format GIF) avec les formules adéquates (cf. Résultats). Si la taille réelle estimée finale est inférieure au seuil max défini, alors la variante sera produite via Ffmpeg.

Pour terminer, il faut noter que nos formules d'estimation se basent sur des tests statistiques réalisés à partir d'échantillon de 6 variantes, ce qui est peu (même si les p-valeurs sont très inférieures au 5% de marge d'erreur). On peut donc penser, si l'on souhaite utiliser un seuil max critique, pousser cette étude pour avoir des coefficients de corrélation plus justes nous permettant de faire moins d'approximation.